

Clasificación de texto en español con redes recurrentes

Taller 05 · Procesamiento de Lenguaje Natural · Pontificia Universidad Javeriana · octubre de 2026

Código, notebook y resultados: https://github.com/davidm094/NLP_JAVE_TALLER05_202601

Se entrenaron redes recurrentes sobre textos de salud mental en español para dos tareas: **binaria** (Normal vs Depression) y **multiclase** (7 clases). Se variaron hiperparámetros de forma sistemática (41 entrenamientos) y se midió el ruido entre semillas para distinguir efectos reales del azar. La tabla resume las respuestas.

Pregunta	Binaria	Multiclase
¿Qué tan bien funciona la RNN base? (test, 3 semillas)	Accuracy 0,948 ± 0,002	F1 macro 0,615 ± 0,009 · accuracy 0,677 (con pesos de clase)
¿Cuánto ruido hay entre semillas? (desv. est. F1 val)	0,0016	0,0115 con pesos de clase; 0,0280 sin pesos
¿Qué hiperparámetros importan?	Casi ninguno: todos los efectos caben en ±0,8 pp de F1	Bidireccionalidad (−12 pp sin ella), celda con compuertas (SimpleRNN −9 pp), vocabulario (1.000 palabras −8 pp)
¿La mejor combinación supera a la base?	No ($p = 0,44$) y es 2,6× más lenta	+0,9 pp, no significativo ($p = 0,46$)
¿Por qué tan pocas épocas?	Sobreaajuste temprano: el embedding concentra el 90 % de los parámetros	Ídem; reducir el embedding a 16 dimensiones mantiene el desempeño con 71 % menos parámetros
Recomendación	BiGRU o BiLSTM con embedding de 16	BiGRU o BiLSTM con embedding de 16 y pesos de clase

1. Método

Datos. Columna *statement_es_es* (53.043 textos, 45 vacíos; mediana 52 palabras). Clases: Normal 31 %, Depression 29 %, Suicidal 20 %, Anxiety 7 %, Bipolar 5 %, Stress 5 %, Personality disorder 2 %.

Tarea	Train	Validación	Test	Partición (semilla 42)
Binaria (Normal, Depression)	22.863	2.541	6.351	test 20 %; validación = 10 % del resto
Multiclase (7 clases)	37.098	5.300	10.600	estratificada 70 / 10 / 20

Modelo base (arquitectura del ejemplo de clase): TextVectorization (vocabulario 10.000, 128 tokens, estandarización adaptada a z_i) → Embedding 64 → Bidirectional(LSTM 64) → Dense 64 relu → salida. Adam lr 1e-3, batch 64, early stopping sobre la pérdida de validación (paciencia 3 en binaria, 1 en multiclase) restaurando la mejor época. En multiclase la base usa **pesos de clase** (ver sección 3).

Protocolo. La validación decide; el test solo se reporta. Métrica principal: F1 macro. La base se entrena con 3 semillas y un efecto se considera real si supera 2 desviaciones estándar (2σ) de ese ruido.

Diseño. De 19 hiperparámetros identificados (inventario en *DISEÑO_EXPERIMENTAL.md*) se variaron 9, uno a la vez: tipo de celda (GRU, SimpleRNN), bidireccionalidad, unidades (128), capas (2), dropout (0,2), learning rate (3e-4), vocabulario (1.000) y longitud (256). Después: la mejor combinación por tarea (3 semillas) y 5 variantes contra el sobreajuste.

2. ¿Qué hiperparámetros importan?




Figura 1. Cambio del F1 macro de validación al variar cada hiperparámetro (una semilla por variación). Cada panel tiene su escala; la banda gris es el ruido entre semillas ($\pm 2\sigma$). Azul: mejora real; naranja: empeora.

Variación (vs base)	Binaria	Multiclase	Tiempo (multiclase)
GRU (vs LSTM)	+0,4 pp (+2,7σ)	+2,0 pp (+1,7σ)	1,0×
SimpleRNN (vs LSTM)	-0,8 pp (-5,0σ)	-9,4 pp (-8,2σ)	0,6×
Unidireccional	-0,2 pp (-1,6σ)	-12,1 pp (-10,6σ)	0,5×
128 unidades (vs 64)	+0,2 pp (+1,4σ)	+0,8 pp (+0,7σ)	1,5×
2 capas (vs 1)	+0,4 pp (+2,5σ)	-2,7 pp (-2,4σ)	1,2×
Dropout 0,2 (vs 0)	-0,1 pp (-0,4σ)	+0,5 pp (+0,4σ)	1,0×
lr 3e-4 (vs 1e-3)	+0,3 pp (+2,2σ)	-3,8 pp (-3,3σ)	1,1×
Vocabulario 1.000 (vs 10.000)	+0,1 pp (+0,7σ)	-8,2 pp (-7,2σ)	0,5×
256 tokens (vs 128)	-0,5 pp (-3,0σ)	+1,1 pp (+1,0σ)	1,8×

Δ F1 macro de validación en puntos porcentuales y en σ de cada tarea. Tiempo relativo a la base multiclase.

- **La binaria es casi insensible:** el problema es fácil y cualquier RNN razonable llega a ~95 % de accuracy.
- **En multiclase importa lo que da capacidad de matiz:** leer en ambos sentidos, celdas con compuertas y un vocabulario suficiente. Bidireccionalidad y vocabulario no importan en binaria pero son decisivos con 7 clases.
- **GRU** es la única variación que no empeora en ninguna tarea y entrena más rápido que LSTM. **Más unidades** no ayudan en ninguna.
- **2 capas y lr 3e-4** empeoran en multiclase, pero aprenden más despacio y allí se usó paciencia 1: resultado débil, posiblemente del protocolo.

3. Multiclase: el desbalance de clases

Base multiclase (3 semillas)	F1 macro val	Accuracy test	Recall Personality disorder
Sin pesos de clase	0,589 ± 0,028	0,712 ± 0,004	0,01-0,46
Con pesos de clase	0,617 ± 0,011	0,677 ± 0,007	0,55-0,66

Sin pesos, el F1 macro depende de la semilla: la clase minoritaria (2 % de los datos) se detecta o se ignora casi por completo. Con pesos de clase el ruido baja 2,4× y esa clase siempre se detecta; a cambio, la accuracy cae ~3,5 pp porque se sacrifica acierto en las clases grandes (sobre todo Depression). La subida del F1 promedio no es significativa ($p = 0,23$); el beneficio es la estabilidad, que hace medibles los demás efectos.





Figura 2. Recall en test por clase (media ± desv. est., 3 semillas).



Dónde se equivoca. La confusión dominante es Depression ↔ Suicidal: 30 % de los textos de Depression se predicen como Suicidal y 17 % al revés. Stress se confunde con Depression (13 %) y Anxiety (10 %). Son clases con vocabulario muy parecido; Normal (88 %) y Anxiety (83 %) son las más fáciles.

Figura 3. Matriz de confusión en test (mejor combinación multiclase, semilla 42). Filas: clase real.

4. ¿Por qué el entrenamiento para en 4-5 épocas?




Figura 4. Pérdida de entrenamiento y validación por época. Línea punteada: mejor época (pesos que se conservan).

Desde la época 1-2 la pérdida de entrenamiento sigue bajando y la de validación sube: es **sobreajuste**. El early stopping se detiene unas épocas después del mínimo y restaura los pesos de la mejor época, por eso el modelo evaluado no es el sobreajustado. La causa es el embedding: 640.000 de los 714.369 parámetros (90 %) son la tabla de 10.000 palabras × 64 dimensiones, unos 31 parámetros por texto de entrenamiento. La accuracy de validación casi no cae aunque la pérdida suba: el modelo se vuelve sobreconfiado, no mucho más errado.

Variante (binaria)	F1 val	Acc. test	Mejor época	Subida pérdida val*	Parámetros
Base (3 semillas)	0,9394	0,9476	1-2	+48 a +58 %	714.369
Embedding 16 (vs 64)	0,9429	0,9512	2	+37 %	209.793
Dropout espacial 0,3 en el embedding	0,9437	0,9487	1	+61 %	714.369
L2 en el embedding (1e-5) **	0,9456	0,9446	2	+33 %	714.369
Dropout 0,5	0,9412	0,9480	1	+42 %	714.369
Embedding 32 + dropout espacial 0,3	0,9385	0,9466	1	+30 %	377.985

* Subida de la pérdida de validación desde su mínimo hasta la última época (menor = menos sobreajuste). ** No del todo comparable: Keras suma la penalización L2 a la pérdida.

Ninguna regularización mueve el desempeño más de ~0,6 pp. Lo útil es el **embedding de 16 dimensiones**: mismo desempeño con 71 % menos parámetros, y en multiclase (F1 val 0,614 vs 0,617 de la base) retrasa la mejor época de la 3-4 a la 6. El sobreajuste es real pero no es el cuello de botella: el early stopping ya rescata el mejor punto.

5. Mejor combinación, conclusiones y limitaciones

Tarea	Modelo (3 semillas)	F1 macro val	F1 macro test	Accuracy test	Tiempo
Binaria	Base: BiLSTM	0,9394 ± 0,0016	0,9476 ± 0,0022	0,9476 ± 0,0022	148 s
	GRU + 2 capas + lr 3e-4	0,9419 ± 0,0045	0,9476 ± 0,0027	0,9476 ± 0,0027	377 s
Multiclase	Base: BiLSTM + pesos	0,6166 ± 0,0115	0,6155 ± 0,0088	0,6771 ± 0,0073	223 s
	GRU + 256 tokens + dropout 0,2 + pesos	0,6252 ± 0,0137	0,6309 ± 0,0115	0,6856 ± 0,0142	444 s

Las combinaciones juntan las variaciones que mejoraron en cada tarea. Ninguna supera a su base de forma significativa (binaria $p = 0,44$, multiclase $p = 0,46$): los efectos individuales no se suman.

Conclusiones

- Una RNN bidireccional simple resuelve la tarea binaria (~95 % de accuracy) y el ajuste de hiperparámetros no aporta mejoras medibles.
- En multiclase los hiperparámetros sí importan; los decisivos son la bidireccionalidad, las celdas con compuertas y el vocabulario.
- El desbalance de clases domina la variabilidad del F1 macro; los pesos de clase la estabilizan a costa de accuracy.
- El modelo sobreajusta desde la época 1-2 por exceso de parámetros en el embedding; uno de 16 dimensiones rinde igual con 71 % menos parámetros.
- Medir el ruido entre semillas fue clave: varias "mejoras" medidas contra una sola semilla resultaron estar dentro del azar.

Limitaciones

- Una semilla por variación y diseño de un factor a la vez (no mide interacciones); los efectos cercanos a 2σ deben leerse con cautela.
- Paciencia 1 en multiclase puede penalizar configuraciones lentas (2 capas, lr bajo).
- Varios hiperparámetros (optimizador, batch, capa densa, dropout recurrente, entre otros) quedaron fijos por costo de cómputo (solo CPU); no se probaron embeddings preentrenados.
- El CSV tiene duplicados: 79 textos del test binario y 156 del multiclase también están en el train.

Reproducibilidad: https://github.com/davidm094/NLP_JAVE_TALLER05_202601 — código (src/), notebook ejecutado, resultados por corrida (results/) y diseño experimental. Una corrida: `python src/correr.py multiclase cw+celda=gru`.